🎬 Movie Rating Predictor – Dokumentace projektu

1. Název projektu

Movie Rating Predictor – predikce hodnocení filmů pomocí strojového učení

2. Cíl projektu

Cílem projektu je vytvořit aplikaci, která dokáže **odhadnout hodnocení filmu (vote_average)** na základě jeho vlastností získaných z reálných dat TMDB (The Movie Database).

Projekt demonstruje kompletní pipeline:

- sběr dat
- čištění dat
- feature engineering
- trénování modelu
- nasazení modelu do webové aplikace

3. Použité technologie

- Python 3
- Pandas, NumPy
- Scikit-learn
- XGBoost
- Matplotlib, Seaborn
- Streamlit
- Requests (API komunikace)
- Joblib (ukládání modelu)

4. Získání dat

Zdroj dat

Data byla získána z veřejného API:
The Movie Database (TMDB API)

Metoda sběru dat

Byl vytvořen vlastní scraper, který:

- stahuje data z endpointu `/movie/popular`
- prochází více stránek (cca 250 stránek)
- ukládá data do CSV souboru

Získané atributy:

- id filmu
- název filmu
- datum vydání
- popularita
- počet hlasů (vote_count)
- průměrné hodnocení (vote_average)
- žánry
- jazyk

5. Předzpracování dat (Data Cleaning)

Data byla upravena v několika krocích:

5.1 Odstranění nevalidních dat

- odstranění řádků s chybějícími hodnotami
- odstranění filmů s nízkým počtem hlasů (< 5)
- filtrování hodnot mimo rozsah (vote_average 1–10)
- odstranění nulové popularity

5.2 Práce s datem

- převod `release_date` na datetime formát
- vytvoření nových feature:
  - `release_year`
  - `release_month`
- výpočet stáří filmu:
  - `film_age = aktuální rok - release_year`

5.3 Odstranění extrémních hodnot

- odstranění outlierů pomocí 99% kvantilu:
  - vote_count
  - popularity

6. Feature Engineering

Byly vytvořeny nové proměnné pro lepší predikci:

Log transformace

- log_vote_count
- log_popularity

Poměrové ukazatele

- engagement_ratio (vote_count / popularity)
- votes_per_year
- popularity_per_year

Další features

- language_rarity (četnost jazyka)
- one-hot encoding jazyků
- encoding žánrů (genre_ids → binární sloupce)
- genre_count
- trend_score
- popularity_score

7. Trénování modelu

Použitý model

- **XGBoost Regressor** (hlavní model)

Další testované modely

- Ridge Regression
- Random Forest
- MLP (Neuronová síť)

Rozdělení dat

- 80 % trénink
- 20 % test

Vyhodnocení modelu

Model byl hodnocen pomocí:

- MAE (průměrná chyba)
- RMSE (velikost chyby)
- R^2 score (vysvětlená variabilita)

8. Výběr modelu

Jako finální model byl zvolen **XGBoost**, protože:

- dosahoval nejlepších výsledků
- měl nejnižší chybu predikce
- dobře pracoval s nelineárními vztahy
- stabilní výsledky při cross-validaci

9. Uložení modelu

Po natrénování byl model uložen:

- `xgb_model.pkl` → natrénovaný model
- `features.pkl` → seznam feature sloupců

10. Webová aplikace

Technologie

- Streamlit

Funkce aplikace

- zadání TMDB ID filmu
- automatické načtení dat z API
- zpracování dat pomocí stejné pipeline jako při tréninku
- predikce hodnocení filmu
- zobrazení výsledku uživateli

Workflow aplikace

1. uživatel zadá ID filmu
2. aplikace stáhne data z TMDB API
3. data se upraví pomocí pipeline
4. model provede predikci
5. výsledek se zobrazí

11. Spuštění projektu

Instalace knihoven

```
pip install -r requirements.txt
```

Spuštění aplikace

```
streamlit run src/app.py
```

12. Shrnutí projektu

Projekt demonstruje kompletní životní cyklus ML aplikace:

- sběr reálných dat z API
- čištění a analýza dat
- feature engineering
- trénování modelu
- evaluace modelu
- nasazení modelu do webové aplikace